

KI-Radar Steuerberatung Deutschland

*Marktlandkarte, Anbieter, Einsatzfelder und
Handlungsempfehlungen*

Berichtsstand: 29. Juli 2026

Beobachtungsfenster: 25. Juni bis 29. Juli 2026, jeweils einschließlich

Zielmarkt: Deutschland und DACH, eingeordnet in den europäischen und globalen Markt

Adressaten: Partnerkreise, Geschäftsführungen, Digital- und IT-Verantwortliche in Steuerkanzleien, Kanzleiverbünden und steuerberatenden Einheiten

Fassung: Master-Dokument

Einordnung. Dieser Radar bewertet nur Vorgänge als „neu“, deren Veröffentlichung oder Wirksamwerden im Beobachtungsfenster belastbar belegt ist. Bestehende Produkte und Marktpositionen werden als Bestand eingeordnet. Leistungs-, Sicherheits- und Benchmarkaussagen von Anbietern werden als solche gekennzeichnet und nicht als unabhängiger Nachweis behandelt.

1. Management Summary

1.1 Radar-Canvas auf einer Seite

Perspektive	Befund zum 29.07.2026	Bedeutung für Steuerkanzleien
Marktimпульs	Die höchste Dynamik kommt aus horizontalen Modellen, Office-Copilots und agentischen Workflow-Plattformen; im steuerfachlichen Kernmarkt ist im Fenster kein belastbar belegter großer Produktneustart erkennbar.	Bestehende Fachsysteme bleiben der Anker. Neue Produktivität entsteht vor allem an ihren Rändern: Recherche, Dokumente, Kommunikation, Tabellen und Workflow-Orchestrierung.
Modelle	OpenAI GPT-5.6, Anthropic Claude Sonnet 5 und Opus 5 sowie Google Gemini 3.6 Flash bzw. 3.5 Flash-Lite wurden im Fenster veröffentlicht.	Modelleleistung und Preise ändern sich schnell. Eine Kanzlei sollte Use Cases und Qualitätskriterien beschaffen, nicht dauerhaft ein einzelnes Modell „fest verdrahten“.
Produkte	Microsoft erweitert Copilot um zentral publizierbare Agenten und MCP-Anbindungen; OpenAI positioniert ChatGPT Work stärker als Arbeitsoberfläche; Cohere North und Mistral Studio operationalisieren Workflows, Prompts und Skills.	Der Schwerpunkt verschiebt sich vom Chatfenster zu kontrollierten, wiederholbaren Prozessen. Das erhöht Nutzen und zugleich Governance-Bedarf.
Steuerfachlichkeit	DATEV konkretisiert eine „AI-integrated“-Strategie; die etablierten Fachrecherche-Angebote von DATEV, Haufe, NWB, Stollfuß, Otto Schmidt/Taxy.io, Deubner, Beck und Wolters Kluwer bleiben relevant.	Fachlich kuratierte Quellen, Quellenbelege und definierte Verantwortlichkeit wiegen im Steuerrecht meist schwerer als reine Modellstärke.
Regulierung	Die EU hat mit der Verordnung (EU) 2026/1744 die Einführungslogik des AI Act materiell geändert. Wesentliche Hochrisiko-Regeln wurden verschoben; andere Pflichten und der allgemeine Anwendungsbeginn bleiben relevant.	Kein Anlass zum Abwarten: Inventar, Kompetenz, Datenschutz, Freigaben, Protokollierung und Lieferantensteuerung sind unabhängig von der Hochrisiko-Verschiebung nötig.
Deutschland	Bundestag und Bundesrat haben das deutsche KI-Marktüberwachungs- und Innovationsgesetz parlamentarisch behandelt; ein belastbarer Nachweis der Verkündung im Bundesgesetzblatt lag zum Stichtag nicht vor.	Die Bundesnetzagentur ist als zentrale Marktüberwachungs- und Servicestelle vorgesehen. Kanzleien sollten die endgültige Verkündung und Vollzugshinweise beobachten.
Datenschutz	EU-Datenresidenz ist kein einheitlicher Zustand: OpenAI, Microsoft und Google bieten differenzierte Zusagen; einzelne Funktionen, Modelle, Subprozessoren oder externe Konnektoren können ausgenommen sein. Anthropic speichert nach eigener Auskunft Daten standardmäßig in den USA.	„EU-Region verfügbar“ ersetzt keine Datenflussprüfung. Entscheidend sind Produktplan, Funktion, Modellroute, Speicherort, Inferenz, Logs, Supportzugriff und angebundene Drittsysteme.

Perspektive	Befund zum 29.07.2026	Bedeutung für Steuerkanzleien
Souveränität	DATEV, IONOS, STACKIT, Mistral und die Cohere/Aleph-Alpha-Kombination besetzen den europäischen Souveränitätsraum; Soofi ist ein interessantes deutsches Modellprojekt, aber noch kein reifes Kanzleiprodukt.	Für besonders sensible Prozesse sind abgestufte Betriebsmodelle sinnvoll. Souveränität muss als überprüfbare Architektur- und Vertragsanforderung formuliert werden.
Ökonomie	Der Markt mischt Sitzplatz-, Paket-, Token-, Credit- und Aktionspreise. Niedrige Tokenpreise sagen wenig über Vollkosten aus; Kontextlänge, Tool-Aufrufe, Caching, Review und Betrieb dominieren häufig.	Vor Rollout sind 30- bis 60-tägige Verbrauchsmessungen pro Use Case nötig. Budgets sollten nach Vorgang und geprüftem Ergebnis geführt werden.
Handlung	Empfohlen wird ein kontrollierter Zwei-Ebenen-Stack: steuerfachlich kuratierte Fach-KI plus ein horizontaler Arbeits-Copilot, ergänzt um einen Governance-Rahmen.	In 90 Tagen lassen sich drei bis fünf messbare Use Cases produktiv etablieren, ohne die Kanzlei auf eine unkontrollierte Agentenlandschaft festzulegen.

1.2 Zehn belastbare Kernaussagen

- Der wichtigste Wandel ist die Produktisierung von Agenten.** Microsoft macht zentral freigegebene Agenten und MCP-Anbindungen in den Office-Anwendungen verfügbar; Cohere North bietet planbare, versionierte Automationen mit Genehmigungsschritten; Mistral Studio führt Prompts und Skills als versionierbare Betriebsobjekte. Das ist für Kanzleien relevanter als ein weiterer Chatbot, weil wiederholbare Arbeitsschritte, Berechtigungen und Nachweise betroffen sind. (Microsoft, 15.07.2026, Cohere, 27.07.2026, Mistral, 09.07.2026)
- Der Modellmarkt hat sich im Fenster erneut deutlich bewegt.** OpenAI veröffentlichte GPT-5.6 am 9. Juli, Anthropic Claude Sonnet 5 am 30. Juni und Claude Opus 5 am 24. Juli, Google neue Flash-Varianten am 21. Juli. Die genannten Leistungsgewinne stammen überwiegend aus Anbieterbenchmarks; für Steuerfälle bleibt ein eigenes Evaluationsset unverzichtbar. (OpenAI, 09.07.2026, Anthropic, 30.06.2026, Anthropic, 24.07.2026, Google, 21.07.2026)
- Das regulatorische Datum 2. August 2026 ist nicht entfallen.** Die Verordnung (EU) 2026/1744 verschiebt Teile der Hochrisiko-Regeln auf 2027 bzw. 2028, lässt aber den allgemeinen Anwendungsbeginn des AI Act und andere Pflichten nicht pauschal verschwinden. Die neue Fassung von Artikel 4 verlangt weiterhin Maßnahmen zur Unterstützung von KI-Kompetenz. (EU, ABl. L 2026/1744)
- Die steuerfachliche Marktmittelpunkt bleibt stabil.** Für die Kernaufgabe „Recherche und Assistenz“ dominieren weiter kuratierte Fachinhalte und bestehende Anbieter. Der DStV hatte Anfang 2026 elf Angebote systematisch erfasst; im aktuellen Fenster ist kein gleichwertiger, belastbar belegter Umbruch dieser Anbieterlandschaft erkennbar. (DStV, Marktübersicht 2026)
- DATEV setzt auf eingebettete statt isolierte KI.** Auf der Jahrespressekonferenz im Juli beschreibt DATEV KI als querschnittliche Funktion in Anwendungen und verweist unter anderem auf Automatisierungsservices, Liquiditätsmonitor, Einspruchsgenerator und DATEV Copilot. Sensible Daten sollen dauerhaft in der DATEV-Infrastruktur verbleiben; Public Cloud werde selektiv und

mit Schutzmaßnahmen genutzt. Das sind strategische Anbieterangaben, keine unabhängige Sicherheitszertifizierung. (DATEV, Pressemappe 17.07.2026)

6. **EU-Residenz muss funktionsbezogen geprüft werden.** Google dokumentiert für Gemini Enterprise, dass Gemini 3.6 Flash in der EU zum Stichtag nur über die globale Route verfügbar ist. Microsoft weist darauf hin, dass Anthropic-Modelle als Subprozessoren derzeit nicht von der EU Data Boundary umfasst sind. OpenAI beschreibt EU-Speicher- und Inferenzresidenz für berechnete Enterprise-/Edu-Kunden, nennt aber Ausnahmen, etwa externe Apps oder bestimmte Systemverarbeitung. (Google Cloud, Microsoft, OpenAI)
7. **Souveränität bleibt ein Portfolio- und kein Ja/Nein-Merkmal.** Europäischer Sitz, EU-Rechenzentrum, Datenresidenz, Modellherkunft, Administrationszugriff, Schlüsselkontrolle, Portabilität und unabhängiger Betrieb sind verschiedene Dimensionen. DATEV formuliert ausdrücklich, vollständige technologische Souveränität sei aktuell nicht erreichbar. Das ist eine realistischere Ausgangslage als pauschale „souverän“-Labels. (DATEV, 17.07.2026)
8. **Preise sind volatiler und weniger vergleichbar geworden.** GPT-5.6 reicht in der API von 1/6 bis 5/30 US-Dollar je eine Million Input-/Output-Token; Claude Sonnet 5 startete mit einem befristeten Einführungspreis von 2/10 US-Dollar, danach 3/15; Opus 5 kostet 5/25. Parallel stehen Kanzleipakete mit Sitzplätzen, Promptkontingenten und Jahresbindungen. (OpenAI, Anthropic Sonnet 5, Anthropic Opus 5)
9. **Ein deutsches Basismodell ist noch kein Kanzleiprodukt.** Soofi-S-Base wird als 30B-A3B-Modell mit rund drei Milliarden aktiven Parametern beschrieben. Die veröffentlichte Modellkarte kennzeichnet es jedoch als geschlossene Beta bzw. Forschungsartefakt, nicht als ausgerichteten Endnutzer-Assistenten. Es gehört auf die Beobachtungsliste, nicht in eine unmittelbare Produktiventscheidung. (Soofi Paper, 10.07.2026, Soofi Modellkarte)
10. **Die richtige Beschaffungslogik ist Use-Case-first.** Für belastbare Ergebnisse sollten Kanzleien je Anwendungsfall Fachquellen, Datenklasse, zulässige Werkzeuge, Qualitätskriterien, Freigabe, Protokollierung, Kosten und Exit definieren. Ein pauschaler „KI-Standardanbieter“ ist angesichts der unterschiedlichen Stärken und Datenflüsse nicht ausreichend.

1.3 Management-Empfehlung

Für die meisten deutschen Steuerkanzleien ist 2026 ein **kontrollierter Zwei-Ebenen-Ansatz** wirtschaftlich und organisatorisch am sinnvollsten:

- **Ebene 1 – steuerfachliche Fach-KI:** eine oder mehrere kuratierte Lösungen für Recherche, Quellenarbeit und klar definierte fachliche Entwürfe;
- **Ebene 2 – horizontaler Arbeits-Copilot:** eine administrierbare Umgebung für E-Mail, Besprechungen, Dokumente, Tabellen, Präsentationen und allgemeine Wissensarbeit;
- **Querschnitt – Governance:** verbindliche Werkzeugliste, Datenklassifikation, Rollen, menschliche Schlussprüfung, Logging, Kompetenzprogramm, Lieferanten- und Kostenkontrolle.

Agentische Automationen sollten erst nach dieser Basis produktiv werden. Sie sind dort sinnvoll, wo ein Prozess stabil, messbar, reversibel und durch Freigabepunkte begrenzt ist.

2. Methodik und Leselogik

2.1 Beobachtungslogik

Der Radar unterscheidet drei Evidenzklassen:

Klasse	Definition	Darstellung
A – Veränderung im Fenster	Veröffentlichung, Verfügbarkeit, Preis-, Lizenz-, Governance- oder regulatorische Änderung zwischen 25.06. und 29.07.2026	Mit Datum und Primärquelle im Veränderungsprotokoll
B – relevanter Marktbestand	Vor dem Fenster bestehende, am Stichtag relevante Position oder Funktion	Als Bestand, ausdrücklich nicht als Neuigkeit
C – Ankündigung oder Anbieterclaim	Künftige Verfügbarkeit, nicht unabhängig validierte Leistungs- oder Sicherheitsbehauptung	Als Ankündigung bzw. Anbieterangabe gekennzeichnet

2.2 Quellenpriorität

Priorisiert wurden:

1. EU-Recht, amtliche deutsche Quellen und Behörden;
2. offizielle Produkt-, Preis-, Datenschutz-, Datenresidenz- und Release-Dokumentation;
3. Verbands- und Berufsstandsquellen;
4. technische Papers und Modellkarten;
5. Sekundärquellen nur zur Plausibilisierung, nicht als tragende Belege volatiler Aussagen.

Preisangaben sind öffentliche Listen- oder Aktionspreise am Stichtag, in der Regel netto und ohne individuelle Rahmenverträge. Anbieterbenchmarks und Kundenbeispiele sind nicht unabhängig nachgemessen.

2.3 Bewertungsmaßstab

Anbieter werden nicht zu einer scheinpräzisen Gesamtrangliste verdichtet. Stattdessen werden sechs Dimensionen separat auf einer Skala von 1 bis 5 bewertet:

- **Steuerrelevanz DE:** Nähe zu deutschen steuerlichen Aufgaben und Kanzleiprozessen;
- **Fachliche Fundierung:** kuratierte Quellen, Zitate, Aktualisierung und Nachvollziehbarkeit;
- **Arbeitsplatz-/Prozessintegration:** Einbindung in Dokumente, E-Mail, Tabellen, DMS und Workflows;
- **Governance:** Administration, Rollen, Protokolle, DPA/AVV, Kontroll- und Freigabefunktionen;
- **Souveränitätsoptionen:** EU-/DE-Betrieb, Hosting-Wahl, Schlüssel- und Portabilitätsoptionen;
- **Marktreife:** produktive Verfügbarkeit, Stabilität, Support und belegte Einsatzbreite.

Skalenanker: 1 = gering oder nicht belastbar belegt; 3 = teilweise bzw. abhängig von Produktplan; 5 = stark und mit Primärquellen belegt. Die Bewertungen sind Entscheidungsorientierung, keine Zertifizierung.

3. Was sich im Beobachtungsfenster tatsächlich verändert hat

3.1 Veränderungsprotokoll 25.06.–29.07.2026

Datum	Veränderung	Evidenzklasse	Relevanz für Steuerberatung
26.06.	OpenAI nimmt GPT-4.5 aus ChatGPT; bestehende Chats wechseln auf GPT-5.5, die API bleibt unverändert.	A	Modellwechsel können reproduzierbare Ergebnisse verändern; Kanzleien brauchen Versions- und Regressionstests. Quelle
30.06.	Anthropic veröffentlicht Claude Sonnet 5 mit befristetem Einführungspreis.	A/C	Neue Option für Dokument- und Agentenarbeit; Leistungswerte sind Anbieterbenchmarks, effektive Kosten hängen auch vom geänderten Tokenizer ab. Quelle
01.07.	Microsoft führt dauerhafte SMB-Pakete „Business Standard/Premium with Copilot“ ein; zugleich werden neue Copilot-Funktionen wie Wasserzeichen, geplante Prompts und labelvererbende Dateierzeugung dokumentiert.	A	Vereinfachte Beschaffung für Kanzleien bis 300 Nutzer; Governance-Funktionen werden enger mit M365 verknüpft. Preisquelle, Release Notes
06.07.	OpenAI stellt ChatGPT for PowerPoint für Enterprise/Edu allgemein bereit; kostenfreie Nutzung bis 06.08., danach Credit-Modell.	A	Präsentationsproduktion wird direkt in Office adressiert; Lizenz- und Creditverbrauch müssen beobachtet werden. Quelle
08./24./27.07.	Der EU-Gesetzgeber beschließt, veröffentlicht und setzt die Verordnung (EU) 2026/1744 in Kraft.	A	Zeitplan und einzelne Pflichten des AI Act ändern sich substantiell; Hochrisiko-Verschiebung ist kein allgemeines Moratorium. Quelle
09.07.	OpenAI veröffentlicht GPT-5.6 Sol, Terra und Luna in ChatGPT, Codex und API; zugleich werden neue Arbeits- und Tooling-Funktionen positioniert.	A/C	Breite Leistungspreisspanne und neue agentische Funktionen; eigene fachliche Evaluation bleibt notwendig. Modellquelle, Arbeitsprodukt
09.07.	Mistral macht versionierte Prompts und Skills in Studio verfügbar.	A	Promptversionen, Rollback, Eigentümer, Audit und Lineage unterstützen kontrollierbaren KI-Betrieb. Quelle
10.07.	Der Bundesrat behandelt das deutsche KI-Marktüberwachungs- und Innovationsgesetz abschließend.	A	Bundesnetzagentur als zentrale Marktüberwachung und Servicestelle vorgesehen; Verkündung war zum Stichtag nicht amtlich nachgewiesen. Bundesrat, Bundestag

Datum	Veränderung	Evidenzklasse	Relevanz für Steuerberatung
10.07.	Das Soofi-Projekt veröffentlicht ein technisches Paper zu einem deutsch-englischen Mixture-of-Experts-Basismodell.	A/C	Strategisch interessant für deutsche Modellkompetenz; aktuelle Modellkarte begrenzt den unmittelbaren Produktiveinsatz. Paper, Modellkarte
13.07.	AWS nimmt GPT-5.6 in Amazon Bedrock auf; Startregionen liegen in den USA.	A	Einheitliche Cloud-Governance möglich, aber keine EU-Region zum Start – relevant für Datenresidenzentscheidungen. Quelle
14.-23.07.	AWS ergänzt AI Protection in GuardDuty, standardisierte Bedrock-Kostenmetadaten und vereinfachte AgentCore-Beobachtbarkeit.	A	Sicherheits-, FinOps- und Betriebsbausteine für größere Kanzleien und Dienstleister werden konkreter. GuardDuty, Kosten, AgentCore
15.07.	Microsoft dokumentiert zentral freigegebene Agenten aus Agent Builder sowie MCP-Agenten in Word, Excel, PowerPoint, Outlook und Catalyst.	A	Agenten können näher an Kanzleiarbeit rücken; zentrale Freigabe, Berechtigungen und Connector-Governance werden zwingend. Quelle
16.07.	Google benennt NotebookLM in Gemini Notebook um und ergänzt geschützte Codeausführung für ausgewählte Tarife.	A	Datenanalyse und Artefakterzeugung werden leistungsfähiger; Tarif- und Administrationsgrenzen sind zu prüfen. Quelle
16./20.07.	xAI veröffentlicht Grok 4.5 und ein kostenloses Excel-Add-in.	A/C	Preislich aggressive horizontale Alternative; für sensible Kanzleidaten fehlen im Vergleich zu führenden Enterprise-Angeboten belastbare DACH-Governance- und Residenznachweise. Modell, Excel
17.07.	DATEV konkretisiert auf der Jahrespressekonferenz die AI-integrated- und Cloud-Strategie.	A/C	Relevanter Richtungsentscheid für den deutschen Kanzleimarkt; konkrete Roadmaps und Verfügbarkeiten sind je Anwendung gesondert zu prüfen. Quelle
20.07.	SAP veröffentlicht die Business-AI-Produktfortschritte des zweiten Quartals 2026.	A/C	Relevant vor allem für große Steuerfunktionen und SAP-nahe Kanzleien; genannte Effizienzwerte sind Anbieter-/Kundenangaben. Quelle
21.07.	Google veröffentlicht Gemini 3.6 Flash und 3.5 Flash-Lite mit neuen API-Preisen.	A/C	Neue Preis-Leistungsoptionen; Gemini 3.6 Flash ist für Gemini Enterprise in der EU zum Stichtag nur global geroutet. Modellquelle, Regionsquelle

Datum	Veränderung	Evidenzklasse	Relevanz für Steuerberatung
24.07.	Anthropic veröffentlicht Claude Opus 5; AWS stellt das Modell ebenfalls bereit.	A/C	Hochleistungsoption mit Premiumpreis; AWS nennt Zero Data Retention als Standard und regionale Residenz, die konkrete Region ist zu wählen. Anthropic, AWS
27.07.	Cohere macht North Automations für alle North-Kunden verfügbar.	A	Versionierte, planbare Workflows mit Verzweigungen, Freigaben und On-Prem-/Cloud-Wahl stärken die europäische Workflow-Alternative. Quelle

3.2 Was ausdrücklich keine neue Entwicklung ist

Folgende Positionen bleiben wichtig, werden aber nicht künstlich als Neuheit des Beobachtungsfensters dargestellt:

- die breite Verankerung von DATEV in deutschen Kanzleiprozessen;
- die seit Anfang 2026 dokumentierte Gruppe steuerfachlicher Rechercheassistenten;
- die generelle Verfügbarkeit von Microsoft 365 Copilot, ChatGPT Enterprise/Business, Gemini Enterprise und Claude for Enterprise;
- der europäische Souveränitätsanspruch von IONOS, STACKIT, OVHcloud, Mistral und Aleph Alpha;
- Mistral OCR 4, dessen Veröffentlichung am 23. Juni 2026 knapp vor dem Beobachtungsfenster lag;
- das Muster einer KI-Anwendungsrichtlinie des DStV vom 23. April 2026.

Diese Punkte bilden den Marktbestand, gegen den die Veränderungen im Fenster bewertet werden.

4. Marktlandkarte

4.1 Vier Marktschichten

Schicht	Typische Anbieter	Primärer Wertbeitrag	Hauptrisiko
Steuerfachliche Systeme und Inhalte	DATEV, Wolters Kluwer ADDISON, Haufe, NWB, Beck, Deubner, Otto Schmidt/Taxy.io, Stollfuß, WTS PSP	Fachrecherche, Quellen, steuerliche Entwürfe, Integration in Kanzleisoftware	Scheinsicherheit trotz Quellenbeleg; Aktualität, Lizenzgrenzen, fehlende Prozessintegration
Horizontale Arbeits-Copilots	Microsoft, OpenAI, Google, Anthropic, DeepL, xAI	E-Mail, Besprechungen, Dokumente, Tabellen, Präsentationen, allgemeine Wissensarbeit	unzulässige Daten, Schatten-KI, Modellwechsel, unklare Residenz einzelner Funktionen
Modell-, Agenten- und Cloud-Plattformen	AWS, Azure, Google Cloud, SAP, Mistral, Cohere/Aleph Alpha, NVIDIA	eigene Workflows, RAG, Agenten, Modellwahl, Monitoring und Skalierung	Entwicklungs- und Betriebsaufwand, Berechtigungsfehler, Kosten- und Lock-in-Risiko
Souveräne Infrastruktur und Basismodelle	IONOS, STACKIT, OVHcloud, Mistral, Aleph Alpha, Soofi	EU-/DE-Betrieb, Portabilität, Daten- und Infrastrukturkontrolle	Funktionsabstand, kleinere Ökosysteme, uneinheitlicher Souveränitätsbegriff

4.2 Steuerfachlicher Kernmarkt

Der Fachmarkt ist fragmentiert, aber nicht ungeordnet. Er folgt überwiegend drei Mustern:

1. **In bestehende Datenbanken eingebettete Assistenz:** etwa DATEV LEXinform plus, Haufe CoPilot Tax, NWB KIRA, beck-chat oder Stollfuß GenIA-L;
2. **spezialisierte Recherche- und Entwurfsflächen:** etwa Deubner Tax KI, Frag den Schmidt oder Taxy.io Answers mit Verlagsinhalten;
3. **kanzleinahe Experimentierräume bzw. Plattformen:** etwa DATEV KI-Werkstatt oder WTS PSP plAlground.

Der DStV dokumentierte für Anfang 2026 elf Angebote. Zehn seien bereits im Betrieb, eines im Pilot; sieben seien in bestehende Produkte eingebettet, vier böten Schnittstellen, drei Internetrecherche. Alle befragten Anbieter hätten Verschlüsselung und den Verzicht auf Training mit Kundeneingaben angegeben. Diese Angaben beruhen auf Anbieterfragebögen und sind daher als Selbstauskunft, nicht als Audit zu lesen. (DStV)X

4.3 Horizontale Arbeitsplattformen

In dieser Schicht entscheidet nicht allein die Modellqualität, sondern die Kombination aus:

- Zugriff auf Dokumente, E-Mail, Kalender, Besprechungen und Tabellen;
- Berechtigungsvererbung und Mandantentrennung;
- Administrations- und Auditfunktionen;
- Datenresidenz je Funktion;
- Konnektoren, Tool-Aufrufen und Agentenfreigaben;
- Export-, Lösch- und Exitfähigkeit.

Microsoft hat durch die Nähe zu M365 für viele Kanzleien einen strukturellen Integrationsvorteil. OpenAI bietet eine breite eigenständige Arbeitsoberfläche und Modell-/Tool-Infrastruktur. Google verbindet Gemini eng mit Workspace und Cloud, Anthropic positioniert Claude stark für anspruchsvolle Dokument- und Agentenarbeit. DeepL bleibt für mehrsprachige Mandatsarbeit eine spezialisierte, etablierte Ergänzung. xAI ist funktional dynamisch, weist aber für einen produktiven DACH-Kanzleieinsatz derzeit mehr offene Governance-Fragen auf.

4.4 Plattform- und Souveränitätsmarkt

Größere Kanzleien und Verbünde können Modelle über Plattformen statt über einzelne Endnutzerprodukte konsumieren. AWS Bedrock, Azure AI, Google Vertex AI und SAP Business AI bieten Governance, Integration und Abrechnung in vorhandenen Cloud-Landschaften. Mistral und Cohere/Aleph Alpha stärken europäische Modell- und Workflow-Optionen; IONOS, STACKIT und OVHcloud bieten europäische Infrastrukturfade.

Die Wahl sollte nicht nach Herkunftsetikett erfolgen, sondern nach einem Souveränitätsprofil:

Dimension	Prüffrage
Recht	Welche Vertragspartei, Rechtsordnung, Subprozessoren und Behördenzugriffe gelten?
Daten	Wo liegen Eingaben, Ausgaben, Dateien, Logs, Backups und Supportdaten?
Inferenz	Wo wird tatsächlich gerechnet, und gilt das für jedes wählbare Modell?
Schlüssel	Wer kontrolliert Verschlüsselungsschlüssel und administrative Notfallzugriffe?
Technologie	Kann die Lösung in anderer Infrastruktur betrieben oder ersetzt werden?

Dimension	Prüffrage
Betrieb	Wer administriert, überwacht und aktualisiert Modelle, Agenten und Konnektoren?
Ökonomie	Welche Wechsel-, Egress-, Migrations- und Revalidierungskosten entstehen?

5. Anbieter- und Lösungsvergleich

5.1 Bewertungsmatrix I – Fach- und Arbeitsfit

Anbieter/Lösung	Steuerrelevanz DE	Fachliche Fundierung	Integration	Kurzbegründung
DATEV	5	5	5	Tiefste Nähe zu deutschen Kanzleiprozessen und eigenen Fachdaten; KI wird schrittweise in Anwendungen eingebettet.
Wolters Kluwer ADDISON	4	2	5	Starke Kanzleisoftware-Integration; fachliche KI-Fundierung je konkretem Modul zu prüfen.
Haufe CoPilot Tax	5	5	4	Kuratierte Haufe-Fachinhalte und kanzleitaugliche Pakete; Integration außerhalb des Haufe-Ökosystems begrenzter.
NWB KIRA	5	5	4	Starke steuerfachliche Quellenbasis; Fokus auf Recherche und Assistenz.
Otto Schmidt/Taxy.io	5	5	3	Hochwertige Verlagsinhalte, Dokument- und Recherchefunktionen; Prozessintegration im Einzelfall prüfen.
Stollfuß GenIA-L	5	5	3	Steuerfachlicher Fokus und Stollfuß-Inhalte; höherpreisiges Sitzplatzmodell.
Deubner Tax KI	5	4	3	Kanzleiweites Angebot mit Fachfokus und definiertem Promptkontingent.
Microsoft	4	2	5	Sehr hohe Arbeitsintegration; keine eigenständige deutsche Steuerquellenbasis.

Anbieter/Lösung	Steuerrelevanz DE	Fachliche Fundierung	Integration	Kurzbegründung
OpenAI	4	2	4	Breite Arbeits- und Tool-Fähigkeiten; Fachgrundlage muss angebunden und validiert werden.
Google	3	2	4	Starke Workspace-/Cloud-Integration; kein steuerfachlicher Quellenkern.
Anthropic	3	2	4	Stark bei Dokumenten und Agenten; Fachgrundlage und EU-Datenarchitektur separat nötig.
DeepL	2	1	5	Spezialist für Sprache und Übersetzung, nicht für steuerfachliche Recherche.
SAP	4	3	4	Relevant für Tax-Funktionen in SAP-Prozessen; für klassische Kanzleien selektiver Fit.
AWS Bedrock	3	2	4	Breite Modell- und Betriebsplattform; Fachlogik muss aufgebaut oder angebunden werden.
Mistral	3	2	3	Europäische Modelle und neue Governance für Prompts/Skills; Fachcontent fehlt nativ.
Cohere/Aleph Alpha	3	2	3	Souveräne Workflow- und Deployment-Optionen; Kanzleifachlichkeit ist Integrationsaufgabe.
IONOS/STACKIT	2	1	2	Infrastruktur- und Modellbereitstellung, kein fertiges steuerfachliches Produkt.
Soofi	1	1	1	Forschungs-/Beta-Status, keine produktionsreife Kanzleilösung.

5.2 Bewertungsmatrix II – Betriebsfit

Anbieter/Lösung	Governance	Souveränitätsoptionen	Marktreife	Entscheidungsnotiz
DATEV	5	4	5	Sehr kanzeleinah; Public-Cloud-Anteile und konkrete Datenflüsse je Anwendung prüfen.
Wolters Kluwer ADDISON	4	3	4	Etablierter Anbieter; modulbezogene Nachweise und Vertragsunterlagen erforderlich.
Haufe CoPilot Tax	4	4	5	Reifes Fachprodukt; Daten- und Modellkette im Vertrag verifizieren.
NWB KIRA	4	4	5	Reifes Fachangebot; Integrations- und Exportanforderungen prüfen.
Otto Schmidt/Taxy.io	4	4	4	EU-/DE-Hosting wird angegeben; Zertifizierungs- und Subprozessorumfang vertraglich prüfen.
Stollfuß GenIA-L	4	4	4	Etabliertes Fachhaus; Tarif- und Mandantentrennung im Pilot testen.
Deubner Tax KI	4	3	4	Azure-OpenAI-Nutzung dokumentiert; Plan-/Regionsdetails und Kontingente prüfen.
Microsoft	5	3	5	Umfassende Administration; Funktions- und Modell-Ausnahmen von der EU Data Boundary beachten.
OpenAI	5	3	5	Starke Enterprise-Kontrollen und EU-Optionen; externe Apps und Restverarbeitung abgrenzen.
Google	4	3	5	Solide Cloud-Governance; aktuelle EU-Routinglücke für Gemini 3.6 Flash beachten.
Anthropic	4	2	5	Enterprise-Kontrollen vorhanden; Standarddatenspeicherung nach Anbieterangabe in den USA.

Anbieter/Lösung	Governance	Souveränitätsoptionen	Marktreife	Entscheidungsnotiz
DeepL	5	4	5	Hohe Reife für Sprachworkflows; konkreten Produktplan und Datenfluss prüfen.
SAP	5	4	5	Stark in regulierten Enterprise-Prozessen; Komplexität und Kosten höher.
AWS Bedrock	5	3	5	Starke Plattform-Governance; regionale Modellverfügbarkeit variiert.
Mistral	4	5	4	Europäische Deployment- und Portabilitätsoptionen; Betriebskompetenz erforderlich.
Cohere/Aleph Alpha	5	5	3	On-Prem-/Cloud-Wahl und Freigaben attraktiv; kombinierte Roadmap beobachten.
IONOS/STACKIT	5	5	3	Souveräne Infrastruktur stark; Anwendungs- und Modellökosystem kleiner.
Soofi	2	5	1	Deutsche Infrastrukturperspektive, aber noch kein ausgerichtetes Produktmodell.

5.3 Profile der strategisch wichtigsten Anbieter

DATEV

Position: Marktanker für deutsche Kanzleiprozesse und Fachdaten.

Aktuelle Veränderung: Die Juli-Kommunikation verdichtet die Strategie zu „AI-integrated“: KI soll dort eingebettet werden, wo sie in fachlichen Anwendungen Nutzen stiftet. Genannt werden unter anderem Automatisierungsservices, Liquiditätsmonitor, Einspruchsgenerator und DATEV Copilot. DATEV meldet aus einer eigenen Befragung, dass etwas mehr als die Hälfte der Kanzleien regelmäßig KI nutze, gegenüber knapp einem Drittel 2025; große Kanzleien lägen bei fast drei Vierteln. Das ist eine DATEV-Erhebung, keine unabhängige Marktschätzung. (DATEV Pressemappe)X

Stärken: Fach- und Prozessnähe, Vertrauensposition, bestehende Daten- und Berechtigungsstrukturen.

Lücken: heterogener Reifegrad je Funktion; offene Abhängigkeiten von Public-Cloud-Komponenten; Roadmap muss je Produkt statt aus der Gesamtstrategie abgeleitet werden.

Empfehlung: DATEV-Funktionen zuerst gegen drei konkrete Prozesskennzahlen testen; parallel die Fähigkeit zu externen, kontrollierten Spezialwerkzeugen erhalten.

Microsoft

Position: stärkste Arbeitsplatzintegration in M365-geprägten Kanzleien.

Aktuelle Veränderung: zentrale Veröffentlichung von Agent-Builder-Agenten, MCP-Agenten in Kernanwendungen sowie dauerhafte SMB-Copilot-Pakete. Die US-Listenpreise liegen ab 1. Juli bei 23,50 US-Dollar pro Nutzer und Monat für Business Standard with Copilot und 32 US-Dollar für Business Premium with Copilot; lokale Preise und Vertragsbedingungen können abweichen. (Partner Center)X

Stärken: Identität, Berechtigungen, Compliance, Dateilabels, Office-Kontext, Administrationsbreite.

Lücken: keine kuratierte deutsche Steuerbasis; Funktions- und Modellabhängigkeiten in der Datenresidenz; zunehmende Agentenkomplexität.

Empfehlung: Agenten standardmäßig gesperrt bzw. genehmigungspflichtig einführen; nur geprüfte Konnektoren freigeben und Datenlabels testen.

OpenAI

Position: horizontaler Innovationsführer mit breitem Endnutzer- und API-Angebot.

Aktuelle Veränderung: GPT-5.6 Sol/Terra/Luna, stärkere Arbeitsoberfläche, programmatic tool calling, Multi-Agent-Beta und erweiterte Cache-Logik. API-Listenpreise je eine Million Token: Sol 5 US-Dollar Input/30 Output, Terra 2,50/15, Luna 1/6. (OpenAI)X

Stärken: Modellbreite, Werkzeuge, Entwicklungsökosystem, Enterprise-Kontrollen, EU-Residenzoptionen für berechnigte Pläne.

Lücken: keine originäre deutsche Steuerquellenbasis; Modell- und Produktwechsel; Residenzausnahmen bei externen Apps und Teilen der Systemverarbeitung.

Empfehlung: als horizontalen Copilot oder Modellgateway nutzen, aber steuerfachliche Antworten ausschließlich mit kuratiertem Quellenkontext und verbindlicher Schlussprüfung.

Google

Position: integrierte Alternative für Workspace- und Google-Cloud-Kunden.

Aktuelle Veränderung: Gemini 3.6 Flash zu 1,50/7,50 US-Dollar und Gemini 3.5 Flash-Lite zu 0,30/2,50 US-Dollar je eine Million Input-/Output-Token; Gemini Notebook erhält Codeausführung für ausgewählte Tarife. (Google)X

Stärken: Workspace-/Cloud-Integration, Modellpalette, Administrations- und Datenkontrollen.

Lücken: keine deutsche Steuerfachbasis; 3.6 Flash in Gemini Enterprise zum Stichtag nicht EU-regional verfügbar.

Empfehlung: nur Modelle und Funktionen zulassen, deren Routing mit der Datenklasse vereinbar ist; globale Routingwarnungen nicht pauschal akzeptieren.

Anthropic

Position: leistungsstarker Anbieter für lange Dokumente, Coding und Agenten.

Aktuelle Veränderung: Sonnet 5 und Opus 5. Sonnet 5 kostet bis 31. August 2/10 US-Dollar und danach 3/15; Opus 5 kostet 5/25 je eine Million Input-/Output-Token, ein schneller Modus das Doppelte. (Sonnet 5, Opus 5)X

Stärken: Dokumentarbeit, Tool-Nutzung, Enterprise-Funktionen.

Lücken: Anthropic erklärt, Daten standardmäßig in den USA zu speichern, auch wenn Traffic-Routing gewählt wird; keine deutsche Steuerbasis. (Anthropic Privacy Center)

Empfehlung: bei sensiblen Daten nur über eine belastbar passende Plattform-/Vertragsroute einsetzen; US-Speicherung in der DSFA bzw. Transferprüfung berücksichtigen.

Mistral

Position: europäische Modell- und Plattformalternative mit Deployment-Flexibilität.

Aktuelle Veränderung: Prompts und Skills werden in Studio als versionierbare Objekte mit Eigentümer, Labels, Rollback, Audit, Telemetrie und MCP-Verknüpfung verwaltet. Mistral gibt an, Daten blieben im gewählten Perimeter. (Mistral)X

Stärken: EU-Herkunft, Betriebsoptionen, Portabilität, gute Governance-Entwicklung.

Lücken: Fachinhalt und Kanzleiintegration müssen aufgebaut werden; betriebliche Verantwortung steigt.

Empfehlung: für Verbünde und größere Kanzleien als kontrollierbare Modellschicht oder souveräne Alternative pilotieren.

Cohere/Aleph Alpha

Position: souveränitätsorientierte Enterprise-Kombination; der geplante Zusammenschluss wurde vor dem Fenster angekündigt.

Aktuelle Veränderung: North Automations ist seit 27. Juli für alle North-Kunden verfügbar. Arbeitsabläufe können natürlichsprachlich erstellt, geplant, verzweigt, versioniert und mit Freigaben versehen werden; Deployment on-premises oder in verschiedenen Clouds wird angeboten. (Cohere)X

Stärken: Deployment-Wahl, Workflow-Governance, europäische Positionierung.

Lücken: Integrations- und Implementierungsaufwand, offene gemeinsame Produktroadmap, keine fertige Steuerfachbasis.

Empfehlung: für sensible, wiederholbare Backoffice-Workflows prüfen, wenn eigener Plattformbetrieb wirtschaftlich ist.

AWS Bedrock

Position: Multi-Modell-Plattform für größere Organisationen und Softwareanbieter.

Aktuelle Veränderung: GPT-5.6 und Claude Opus 5, GuardDuty AI Protection, Kostenmetadaten und AgentCore-Observability. GPT-5.6 startete nur in US-Regionen; Claude Opus 5 wird mit Zero Data Retention als Standard und regionaler Residenz beworben. (AWS GPT-5.6, AWS Claude Opus 5)X

Stärken: Modellwahl, Infrastrukturintegration, Sicherheits- und Kostenwerkzeuge.

Lücken: regionale Verfügbarkeit je Modell; hohe Architektur- und Betriebsanforderungen.

Empfehlung: nur für Kanzleien, Verbünde oder Anbieter mit Cloud-Governance und dediziertem Plattformbetrieb.

SAP

Position: wichtig für steuernahe Unternehmensprozesse, Konzernsteuerfunktionen und SAP-nahe Beratung.

Aktuelle Veränderung: SAP bündelt Q2-Fortschritte rund um Joule und Business AI. Genannte Effizienzsteigerungen, etwa für einen PwC-VAT-Workflow, sind Kunden-/Anbieterangaben. (SAP)X

Stärken: Prozesskontext, Datenmodell, Enterprise-Governance.

Lücken: Komplexität, Kosten und geringerer Fit für kleine klassische Kanzleien.

Empfehlung: dort priorisieren, wo Steuerprozesse bereits in SAP stattfinden; keine parallele Schattenplattform aufbauen.

IONOS, STACKIT und OVHcloud

Position: europäische Infrastruktur- und Modellbereitstellung mit Souveränitätsfokus.

Aktuelle Veränderung: Im Beobachtungsfenster ist kein vergleichbar großer, für Steuerkanzleien unmittelbar wirksamer Produktwechsel belegt.

Stärken: EU-Infrastruktur, Kontroll- und Beschaffungsoptionen, geringere Abhängigkeit von US-Hyperscalern.

Lücken: kleinere Anwendungsmärkte und höherer Integrationsanteil.

Empfehlung: als Hosting-/Modellschicht bewerten, nicht mit einem sofort nutzbaren Steuerassistenten verwechseln. (IONOS AI Model Hub, IONOS EU-AI-Governance, STACKIT)X

Soofi

Position: deutsches Forschungs- und Infrastrukturprojekt für ein deutsch-englisches Basismodell.

Aktuelle Veränderung: Paper im Fenster; die Modellkarte bezeichnet Soofi-S-Base als geschlossene Beta und nicht ausgerichtetes Basismodell.

Stärken: deutscher Entwicklungs- und Infrastrukturbezug, potenzielle Basis für souveräne Anwendungen.

Lücken: keine Endnutzer-Ausrichtung, keine belastbare Kanzleifachlichkeit, eingeschränkte Verfügbarkeit.

Empfehlung: Quartalsweise beobachten; derzeit kein Shortlist-Kandidat für produktive Facharbeit.

5.4 Steuerfachliche Spezialangebote im Überblick

Angebot	Fachlicher Kern	Öffentliche Preis-/Lizenzindikation am Stichtag	Veränderung im Fenster
DATEV LEXinform plus	KI-gestützte Recherche in DATEV-Fachinformationen, Quellenbezug	2026 mit 50%-Aktion; LEXinform comfort Voraussetzung	Keine eigenständige Produktneueinführung belegt; Teil der im Juli bekräftigten KI-Strategie. Produktseite
DATEV Einspruchsgenerator	Entwurf von Einsprüchen aus Bescheiden und Sachverhalt	Produktabhängige DATEV-Lizenz	Bestand; im Juli erneut als KI-Anwendungsbeispiel genannt. Produktseite
DATEV Copilot	allgemeine Assistenz innerhalb des DATEV-Umfelds	Produkt-/Pilotstatus je Angebot prüfen	Strategische Einordnung im Juli, keine pauschale neue Verfügbarkeit behauptet. Produktseite
Haufe CoPilot Tax	steuerfachliche Recherche und Assistenz auf Haufe-Inhalten	Jahrespakete; z. B. Basic Plus 1.059 Euro/Jahr für drei Zugänge laut Shop	Kein wesentlicher Wechsel im Fenster belegt. Shop
NWB KIRA	Recherche, Zusammenfassung und fachliche Assistenz auf NWB-Inhalten	Kanzleipakete, tarifabhängig	Kein wesentlicher Wechsel im Fenster belegt. Shop
Stollfuß GenIA-L	steuerrechtliche Recherche/Assistenz	239 Euro je Nutzer/Monat; weitere Nutzer 71,70 Euro, jeweils laut Shop	Kein wesentlicher Wechsel im Fenster belegt; höher als DSTV-Indikation Anfang 2026. Shop

Angebot	Fachlicher Kern	Öffentliche Preis-/Lizenzindikation am Stichtag	Veränderung im Fenster
Deubner Tax KI	steuerfachliche Fragen, Dokumente und Entwürfe	99 Euro/Monat netto kanzleiweit, 500 Prompts, 14-Tage-Test, monatlich kündbar	Kein wesentlicher Wechsel im Fenster belegt. Anbieter nennt Azure OpenAI. Shop
Otto Schmidt/Taxy.io Answers	Recherche auf Otto-Schmidt-Inhalten, Dokumentupload	149 Euro/Monat netto laut Taxy.io, monatlich kündbar	Aktuelle Vermarktungs-/Tarifdarstellung weicht von der DStV-Momentaufnahme Anfang 2026 ab; Änderungsdatum nicht sicher dem Fenster zuordenbar. Produkt
beck-chat	Assistenz auf beck-online-Inhalten	paket-/vertragsabhängig	Kein wesentlicher Wechsel im Fenster belegt.
Wolters Kluwer ADDISON KI-Assistent	Assistenz im ADDISON-Umfeld	paket-/vertragsabhängig	Kein wesentlicher Wechsel im Fenster belegt.
WTS PSP plAlground	Plattform-/Experimentierumgebung für fachliche KI	projekt-/vertragsabhängig	Kein wesentlicher Wechsel im Fenster belegt.

Hinweis zur Vergleichbarkeit: Promptkontingente, Sitzplätze, Quellenumfang, Daten-Uploads, API-Zugriff, Support und Mindestlaufzeit unterscheiden sich. Eine reine Monatszahl ist kein belastbarer TCO-Vergleich.

6. Einsatzfelder in der Steuerkanzlei

6.1 Reife- und Risikomatrix

Einsatzfeld	Reifegrad	Typischer Nutzen	Hauptrisiko	Empfohlene Kontrolle
Steuerfachliche Recherche mit Quellen	Produktiv	schnellere Erstorientierung, Quellenbündel, Varianten	veraltete/erfundene Quellen, falsche Subsumtion	nur kuratierte Quellen; Fundstellen öffnen; Vier-Augen-Schlussprüfung
Zusammenfassung von Urteilen, BMF-Schreiben und Mandantenunterlagen	Produktiv	Zeitgewinn und einheitliche Struktur	Auslassung von Ausnahmen oder Fristen	Pflichtfelder, Stichproben, Vergleich mit Original
Entwurf von Mandantenkorrespondenz	Produktiv	Tonalität, Struktur, Mehrsprachigkeit	unzulässige Aussage, vertrauliche Daten, falscher Empfänger	Vorlagen, Datenklasse, menschliche Freigabe, Empfängerprüfung
Besprechungsnotizen und Aufgabenlisten	Produktiv mit Grenzen	weniger Nacharbeit, bessere Übergaben	Einwilligung, besondere Kategorien, Fehlzuordnung	klare Aufzeichnungsregel, Löschfrist, Aufgabenbestätigung
Übersetzung	Produktiv	mehrsprachige Kommunikation und Dokumentvorbereitung	Bedeutungsverschiebung bei Fachbegriffen	Glossar, Fachprüfung, keine ungeprüfte Rechtswirkung

Einsatzfeld	Reifegrad	Typischer Nutzen	Hauptrisiko	Empfohlene Kontrolle
Tabellenanalyse und Berichtsentwürfe	Produktiv/Pilot	Plausibilisierung, Erläuterungen, Visualisierung	Formel- und Periodenfehler, versteckte Annahmen	Quellzellen referenzieren, Rechenkontrolle, Versionssperre
Einspruchs- und Stellungnahmeentwürfe	Produktiv mit hoher Prüfung	schnellere Strukturierung und Argumentationsvarianten	Frist, Sachverhalt, Rechtsstand, Haftung	Verantwortlicher Berufsträger, Aktenbezug, Quellen- und Fristencheck
Beleg- und Buchungsvorbereitung	Produktiv in Fachsystemen	Automatisierung repetitiver Erfassung	falsche Kontierung, schlechte Scanqualität, Sonderfälle	Schwellenwerte, Ausnahmequeue, Lern-/Korrekturschleife
Internes Kanzleiwissen/RAG	Pilot bis produktiv	wiederverwendbare Arbeitsanweisungen und Muster	veraltete Versionen, Berechtigungsleck, widersprüchliche Quellen	Dokumenteigner, Gültigkeitsdatum, ACL-Vererbung, Zitierpflicht
Agentische Posteingangs- und Workflow-Steuerung	Pilot	Routing, Datensammlung, Entwurf, Follow-up	Kettenfehler, überbreite Rechte, externe Aktion	kleinste Rechte, Simulation, Freigabegates, Kill Switch, vollständiges Logging
Personal-, Kredit- oder Leistungsentscheidungen	Beobachten/strikt prüfen	mögliche Vorstrukturierung	DSGVO, Diskriminierung, potenziell Hochrisiko	Rechtsprüfung, DSFA, keine autonome Entscheidung, ggf. Verzicht

6.2 Priorisierte Use Cases für die nächsten 90 Tage

Priorität 1 – Fachrecherche mit Belegkette. Ein abgegrenztes Themengebiet wählen, 30 bis 50 reale Altfälle anonymisiert evaluieren und Antwortqualität, Quellenpräzision, Bearbeitungszeit und Reviewaufwand messen.

Priorität 2 – Mandantenkommunikation ohne Fachentscheidung. Entwürfe für Anforderungslisten, Erläuterungen und Terminerinnerungen aus freigegebenen Vorlagen; Versand bleibt menschlich.

Priorität 3 – Dokumentzusammenfassung. Standardisierte Extraktion von Sachverhalt, Zeitraum, Beträgen, Fristen, offenen Fragen und Quellen aus Bescheiden oder Verträgen; Pflichtabgleich mit dem Original.

Priorität 4 – Besprechungs- und Aufgabenübergabe. Nur in administrierter Umgebung, mit definierter Aufzeichnungskommunikation, Löschrufen und bestätigten Aufgaben.

Priorität 5 – Tabellen- und Berichtserläuterung. Abweichungsanalysen, Managementtexte und Visualisierungen aus kontrollierten Daten; Rechenlogik bleibt deterministisch.

Agentische Außenaktionen, autonome Fristenbearbeitung oder selbstständige fachliche Freigaben gehören nicht in die erste Welle.

6.3 Qualitätsstandard für fachliche KI-Ausgaben

Jede fachlich relevante Ausgabe sollte mindestens enthalten:

- Sachverhaltsannahmen und offene Punkte;
- Rechtsstand und Stichtag;

- verwendete Quellen mit direkt prüfbaren Fundstellen;
- Trennung zwischen Quelle, Schlussfolgerung und Unsicherheit;
- alternative Würdigung bei strittiger Lage;
- Name/Rolle der prüfenden Person;
- Ergebnis der Schlussprüfung und verwendete Werkzeug-/Modellversion.

7. Datenschutz, Governance, Souveränität und Regulierung

7.1 Regulatorischer Stand

Die am 24. Juli veröffentlichte und am 27. Juli in Kraft getretene Verordnung (EU) 2026/1744 ändert den AI Act insbesondere in der Einführungslogik:

- Der allgemeine Anwendungsbeginn bleibt grundsätzlich der **2. August 2026**.
- Die zentralen Hochrisiko-Anforderungen für Systeme nach Anhang III/Artikel 6 Absatz 2 werden auf **2. Dezember 2027** verschoben.
- Für produktbezogene Hochrisikosysteme nach Anhang I/Artikel 6 Absatz 1 gilt **2. August 2028**.
- Für bereits bestehende generative Systeme wird die Erfüllung bestimmter Kennzeichnungspflichten nach Artikel 50 Absatz 2 bis **2. Dezember 2026** adressiert.
- Artikel 4 verpflichtet Anbieter und Betreiber weiterhin, Maßnahmen zur Unterstützung der Entwicklung ausreichender KI-Kompetenz zu ergreifen; die Formulierung wurde gegenüber einer individuellen Ergebnisgarantie pragmatisiert.
- „Agentic AI“ wird in der geänderten Systematik ausdrücklich als eigener Code geführt.

Die konkrete Betroffenheit einer Kanzlei hängt von ihrer Rolle als Betreiber, möglicher Eigenentwicklung, dem Use Case und dem Risikotyp ab. Klassische Recherche- und Textassistenten sind nicht automatisch Hochrisiko. Personalentscheidungen, Zugangs- oder Bewertungsprozesse können dagegen deutlich sensibler sein. Primärquelle ist der konsolidierende Änderungsrechtsakt; eine Einzelfallklassifikation ersetzt dieser Bericht nicht. (Verordnung (EU) 2026/1744, AI Act 2024/1689)X

In Deutschland sieht das parlamentarisch behandelte KI-Marktüberwachungs- und Innovationsgesetz die Bundesnetzagentur als zentrale Marktüberwachungsbehörde, Servicestelle und Reallabor-Koordinatorin vor. Zum Redaktionsschluss war in den geprüften amtlichen Quellen keine Verkündung im Bundesgesetzblatt nachgewiesen; daher wird nicht behauptet, das Gesetz sei bereits in Kraft. (Bundesregierung, Bundesnetzagentur)

7.2 Mindest-Governance für Kanzleien

Baustein	Mindeststandard 2026
KI-Inventar	Tool, Produktplan, Modell, Eigentümer, Zweck, Nutzer, Datenklassen, Schnittstellen, Vertrag, Löschfrist und Status erfassen
Zulässigkeitsmatrix	freigegebene Kombination aus Werkzeug × Use Case × Datenklasse × Risikostufe
Berufsgeheimnis	§ 203 StGB, Verschwiegenheit und Einbindung externer Dienstleister vertraglich und organisatorisch prüfen
Datenschutz	Rechtsgrundlage, AVV/DPA, Subprozessoren, Drittlandtransfer, Löschung, Betroffenenrechte und ggf. DSFA
Fachqualität	Quellenpflicht, Testset, Schwellenwerte, Vier-Augen-Prüfung und dokumentierte Verantwortung

Baustein	Mindeststandard 2026
Identität/Rechte	Single Sign-on, kleinste Rechte, getrennte Rollen, Connector-Freigaben, keine geteilten Konten
Protokollierung	relevante Ein-/Ausgaben, Tool-/Modellversion, Quellen, Freigaben und Außenaktionen nachvollziehbar halten
Change Management	Release Notes beobachten, Regressionstests bei Modell-/Prompt-/Datenänderung, Rollback ermöglichen
Incident Response	Abschalten, Zugriff entziehen, Betroffene/Datenschutz einbinden, Fehlerfälle sichern und lernen
Kompetenz	rollenbezogene Schulung, Praxisübungen, Aktualisierung und Nachweis der Maßnahmen
Kostenkontrolle	Nutzer-, Credit-, Token-, Tool- und Reviewkosten pro Use Case messen
Exit	Datenexport, Prompt-/Workflow-Portabilität, Vertragsende, Löschung und Ersatzmodell testen

Der DStV schlägt in seiner Muster-KI-Anwendungsrichtlinie ebenfalls eine Verknüpfung von Tool, Use Case, Daten und Risiko vor und verweist auf AVV, § 203 StGB und menschliche Verantwortung. Die Richtlinie liegt außerhalb des Beobachtungsfensters, bleibt aber eine geeignete Umsetzungsbasis. (DStV, 23.04.2026)

7.3 Datenklassifikation

Klasse	Beispiele	Grundregel
Grün	öffentliche Gesetzes-/Verwaltungsquellen, freigegebene Marketingtexte, synthetische Testfälle	in freigegebenen Werkzeugen zulässig
Gelb	interne Arbeitsanweisungen, pseudonymisierte Fälle, allgemeine Mandatskommunikation	nur administrierte Business-/Enterprise-Umgebung, Zweckbindung und Löschregel
Rot	identifizierbare Steuerdaten, besondere Kategorien, Lohn-/Gesundheitsdaten, Zugangsdaten, straf- oder streitbefangene Sachverhalte	nur explizit freigegebener Use Case mit geprüfter Vertrags-, Residenz-, Berechtigungs- und Protokollarchitektur; andernfalls nicht eingeben

7.4 Datenresidenz: die wichtigsten Fallstricke

OpenAI: Für berechnete neue Enterprise-/Edu-Kunden werden Speicherung in Europa und GPU-Inferenzresidenz angeboten. Nicht jede CPU-/Systemverarbeitung und nicht jeder Datenfluss über externe Apps oder Webzugriffe ist umfasst. Für Business- und Enterprise-Daten wird keine Nutzung zum Training standardmäßig zugesagt. (Residenz, Enterprise Privacy)X

Microsoft: Prompts und Antworten werden verschlüsselt gespeichert und nicht zum Training der Grundmodelle genutzt. Für EU-Nutzer gilt die EU Data Boundary im beschriebenen Umfang. Microsoft weist jedoch darauf hin, dass Anthropic-Modelle als Subprozessoren derzeit außerhalb dieser Boundary liegen. Agenten und Konnektoren folgen eigenen Berechtigungs- und Datenwegen. (Microsoft Privacy)

Google: Google Cloud sagt zu, Kundendaten nicht ohne Erlaubnis zum Training zu nutzen. Die Gemini-Enterprise-Regionsmatrix muss je Modell geprüft werden; Gemini 3.6 Flash ist zum Stichtag für die EU nur über eine globale Route verfügbar. (Google Cloud Datenschutz, Regionsmatrix)

Anthropic: Die Anbieterhilfe nennt globale Traffic-Routing-Optionen, erklärt jedoch, Daten würden standardmäßig in den USA gespeichert; bestimmte Sicherheits- und Supportverarbeitung könne an weiteren Orten stattfinden. (Anthropic)

AWS: Datenresidenz ist modell- und regionsspezifisch. GPT-5.6 startete in US-Regionen. Für Claude Opus 5 nennt AWS regionale Residenz und Zero Data Retention als Standard. Diese Aussagen dürfen nicht modellübergreifend verallgemeinert werden. (GPT-5.6, Claude Opus 5)

8. Preis- und Lizenzlogik

8.1 Vier Beschaffungsmodelle

Modell	Beispiele	Vorteil	Risiko
Sitzplatz/Monat	M365 Copilot, GenIA-L, Taxy.io	planbar, einfacher Rollout	ungenutzte Lizenzen, Funktions-/Kontingentgrenzen
Kanzlei-/Paketpreis	Deubner, Haufe-/NWB-Kanzleipakete	Nutzung im Team, fachlicher Inhalt gebündelt	Paketvergleich schwierig, Jahresbindung
Token/API	OpenAI, Anthropic, Google, Mistral	nutzungsbezogen, modellflexibel	variable Kosten, Kontext- und Toolkosten, Betriebsaufwand
Credits/Aktionen	ChatGPT for PowerPoint, Copilot-Aktionen, Einführungsrabatte	niedrige Einstiegshürde	Preis nach Aktion, schwer prognostizierbarer Verbrauch

8.2 Aktuelle Modellpreisanker

Modell	Input	Output	Besonderheit
OpenAI GPT-5.6 Sol	5,00 USD	30,00 USD	je 1 Mio. Token; hochpreisigste 5.6-Variante
OpenAI GPT-5.6 Terra	2,50 USD	15,00 USD	mittlere Variante
OpenAI GPT-5.6 Luna	1,00 USD	6,00 USD	günstige Variante
Anthropic Claude Sonnet 5	2,00 USD bis 31.08., danach 3,00 USD	10,00 USD bis 31.08., danach 15,00 USD	geänderter Tokenizer kann laut Anbieter Tokenmenge erhöhen
Anthropic Claude Opus 5	5,00 USD	25,00 USD	Fast Mode zum doppelten Preis
Google Gemini 3.6 Flash	1,50 USD	7,50 USD	EU-Routing in Gemini Enterprise zum Stichtag eingeschränkt
Google Gemini 3.5 Flash-Lite	0,30 USD	2,50 USD	preisorientierte Variante

Alle Werte je eine Million Token nach öffentlichen Anbieterangaben am 29. Juli 2026. Caching, Batch, Tool-Aufrufe, lange Kontexte und Plattformaufschläge können abweichen. (OpenAI, Anthropic Sonnet, Anthropic Opus, Google)

8.3 TCO-Formel

Für einen belastbaren Pilot sollten monatlich mindestens folgende Kosten erfasst werden:

TCO je freigegebenem Vorgang = Lizenz/Verbrauch + Integration + Betrieb + menschliche Prüfung + Fehlerkorrektur + Schulung + Governance

Die wichtigste Kennzahl ist nicht „Kosten pro Prompt“, sondern **Kosten pro fachlich akzeptiertem Ergebnis**. Ein billigeres Modell kann durch höheren Reviewaufwand teurer sein; ein hochpreisiges Modell ist ohne messbar bessere Akzeptanz ebenfalls unwirtschaftlich.

9. Handlungsempfehlungen nach Kanzleigröße

9.1 Kleine Kanzlei, bis etwa 20 Mitarbeitende

Zielbild: zwei administrierte Werkzeuge, drei klare Use Cases, kein Eigenbau.

- ein steuerfachliches Rechercheprodukt anhand realer Fälle auswählen;
- den bereits vorhandenen Office-Stack nutzen, sofern Business-/Enterprise-Schutz und Administration genügen;
- private Konten und nicht freigegebene Browsertools untersagen;
- eine einseitige KI-Richtlinie plus Datenklassifikation einführen;
- Partner-/Berufsträgerfreigabe für fachliche und externe Ausgaben beibehalten;
- monatlich Lizenzen, Nutzungsquote, Zeitgewinn und Fehlerfälle prüfen.

Nicht priorisieren: eigenes RAG, Multi-Agent-Systeme, autonome Postbearbeitung, parallele Lizenzen für mehrere horizontale Copilots.

9.2 Mittlere Kanzlei, etwa 21 bis 100 Mitarbeitende

Zielbild: Dual Stack, zentrales Governance-Board und kontrollierter Wissenspilot.

- Fach-KI und Office-Copilot getrennt beschaffen und in einer Use-Case-Matrix verbinden;
- SSO, Rollen, Gruppen, Datenlabels und Connector-Freigaben technisch durchsetzen;
- internes Wissenssystem mit 50 bis 200 gepflegten Dokumenten pilotieren;
- ein fachliches Regressionstestset mit mindestens 50 Fällen aufbauen;
- Agenten nur für interne, reversible Abläufe mit Freigabegates einsetzen;
- Einkauf, Datenschutz, IT-Sicherheit, Berufsrecht und Fachbereich in ein kleines KI-Board bündeln;
- Kosten je akzeptiertem Vorgang und Rework-Quote führen.

9.3 Große Kanzlei, Verbund oder steuerberatende Organisation

Zielbild: Multi-Modell-Gateway, abgestufte Souveränität und systematisches Agentenportfolio.

- Modelle über eine kontrollierte Plattform bzw. ein Gateway austauschbar machen;
 - Datenklassen an erlaubte Regionen, Modelle, Tools und Connectoren binden;
 - zentrale Prompt-/Skill-Versionierung, Evaluation, Observability und Incident-Prozesse etablieren;
 - Fachquellen als kontrollierten Retrieval-Layer bereitstellen;
 - Agenten nach Prozessrisiko klassifizieren und Außenaktionen technisch genehmigungspflichtig machen;
 - europäischen bzw. privaten Betriebsweg für besonders sensible Use Cases vorhalten;
 - Exit-, Last-, Residenz- und Wiederanlauf-tests in die Lieferantensteuerung aufnehmen;
 - Modellwechsel nur nach automatisierten Regressionstests freigeben.
-

10. 90-Tage-Umsetzungsplan

Zeitraum	Arbeitspaket	Ergebnis/Abnahmekriterium
Tage 1-15	Inventar und Sperrzone	100 % der bekannten KI-Werkzeuge erfasst; private Konten und unfreigegebene Connectoren adressiert
Tage 1-20	Use-Case-Auswahl	drei bis fünf Fälle mit Volumen, Ausgangszeit, Datenklasse, Verantwortlichem und Ziel-KPI
Tage 10-30	Vertrags-/Datenprüfung	AVV/DPA, Subprozessoren, Region, Löschung, Training, Logs, Supportzugriff und Exit dokumentiert
Tage 15-35	Qualitätsbaseline	30-50 reale oder synthetisch-anonymisierte Fälle; Sollantworten und Fehlertaxonomie
Tage 25-55	Konfigurierter Pilot	SSO, Rollen, Datenregeln, Vorlagen, Quellenpflicht und Logging aktiviert
Tage 40-70	Schulung und Betrieb	rollenbezogene Übungen; mindestens 80 % der Pilotnutzer bestehen Praxistest
Tage 55-80	Messung	Zeit, Akzeptanz, Rework, Fehler, Kosten und Nutzerquote über mindestens vier Wochen
Tage 75-90	Go/Change/Stop	dokumentierte Entscheidung je Use Case; Budget, Owner, Kontrollplan und nächster Reviewtermin

10.1 Entscheidungstore

Ein Use Case geht nur produktiv, wenn:

1. Zweck, Datenklasse und Verantwortlicher feststehen;
2. Vertrag, Datenfluss und Löschung geprüft sind;
3. Qualitätsschwelle und Testset erfüllt werden;
4. menschliche Freigabe und Eskalation definiert sind;
5. Kosten pro akzeptiertem Ergebnis plausibel sind;
6. Abschaltung, Export und Anbieterwechsel praktisch möglich sind.

10.2 KPI-Set

KPI	Definition	Richtwert für Pilotentscheidung
Zeitersparnis	Differenz zur manuellen Baseline inkl. Prüfung	positiv und über vier Wochen stabil
First-pass acceptance	Anteil ohne wesentliche Überarbeitung	use-case-spezifisch, bei Routineentwürfen typischerweise >70 % anstreben
Kritische Fehler	falsche Frist, Quelle, Betrag, Empfänger oder Rechtsaussage	0 toleriert; jeder Fall Ursachenanalyse
Quellenpräzision	Anteil korrekter, erreichbarer Fundstellen	bei Fachrecherche nahe 100 %

KPI	Definition	Richtwert für Pilotentscheidung
Rework-Quote	Anteil mit substanzieller menschlicher Neuerstellung	sinkend und wirtschaftlich vertretbar
Kosten je akzeptiertem Ergebnis	Vollkosten geteilt durch freigegebene Ergebnisse	unter manueller Baseline oder strategisch begründet
Aktive Nutzung	aktive Pilotnutzer/Lizenznutzer	>60 % nach vier Wochen oder Lizenzbereinigung
Policy-Verstöße	unzulässiges Tool, Datenklasse oder Außenaktion	0; technische Gegenmaßnahme nach jedem Ereignis

11. Risiken und Gegenmaßnahmen

Risiko	Eintritt/Wirkung	Frühindikator	Gegenmaßnahme
Halluzinierte oder veraltete Fachquelle	mittel/hoch	nicht öffnende Fundstelle, unplausibles Datum	kuratierte Quellen, Linkprüfung, Sollfallset, Schlussprüfung
Unzulässige Offenlegung von Mandantendaten	mittel/sehr hoch	private Konten, Copy/Paste außerhalb Freigabeliste	DLP, SSO, Sperrregeln, Schulung, sanktionierte Alternativen
Agent überschreitet Befugnisse	mittel/sehr hoch	Außenaktionen ohne Vorschau, breite Connectorrechte	kleinste Rechte, Sandbox, Freigabegate, Kill Switch
Modellwechsel verschlechtert Qualität	hoch/mittel bis hoch	veränderte Tonalität, längere/abweichende Antworten	Versionskontrolle, Regressionstest, Rollback
Vendor Lock-in	mittel/hoch	proprietäre Prompts, Daten und Workflows ohne Export	offene Formate, Gateway, Exporttest, Exit-Klauseln
Kosten eskalieren	mittel/mittel	lange Kontexte, unklare Credits, Agentenschleifen	Budgets, Alerts, Caching, Modellrouting, Vorgangskosten
Scheinsouveränität	mittel/hoch	EU-Marketing ohne Funktions-/Subprozessorbeleg	Souveränitätsprofil und vertragliche Nachweise
Schatten-KI	hoch/hoch	unbekannte Browsererweiterungen und Privatkonten	brauchbare freigegebene Alternative, Inventar, technische Kontrolle
Kompetenzgefälle	hoch/mittel	unkritisches Vertrauen oder vollständige Ablehnung	rollenbezogene Übungen, Fehlerbibliothek, Champions
Regulatorische Fehlinterpretation	mittel/hoch	„alles verschoben“ oder „jede KI ist Hochrisiko“	Use-Case-Klassifikation, Rechtsmonitoring, dokumentierte Annahmen

12. Handlungsempfehlungen für die Anbieter- und Beschaffungsentscheidung

12.1 Muss-Kriterien

- belastbare Fachquellen oder kontrollierbare Anbindung eigener Quellen;
- Business-/Enterprise-Vertrag, keine privaten Standardkonten;

- dokumentierter Umgang mit Training, Speicherung, Inferenz, Logs und Löschung;
- AVV/DPA, Subprozessorliste und Drittlandmechanismus;
- SSO, Rollen, Nutzerverwaltung und Audit;
- klare Produkt-/Modellversion sowie Release-Kommunikation;
- Quellen-, Export- und Löschfähigkeit;
- Kostenlimits und nutzungsbezogene Reports;
- definierter Support- und Incident-Prozess;
- Pilot ohne langfristigen Lock-in.

12.2 Soll-Kriterien

- EU-/DE-Inferenz und Speicherung für rote Datenklassen;
- kundenseitig kontrollierte Schlüssel oder private Deployment-Option;
- offene Schnittstellen, MCP nur kontrolliert und zentral freigegeben;
- Prompt-/Skill-Versionierung und Rollback;
- automatisierbare Evaluation und Observability;
- Mandantentrennung, Datenlabels und DLP-Integration;
- Modellrouting nach Qualität, Kosten und Datenklasse.

12.3 Ausschlusskriterien

- Nutzung von Eingaben/Dateien zum Training ohne ausdrückliches Opt-in;
- nicht benannte Subprozessoren oder unklare Löschlogik;
- keine Möglichkeit, Nutzer und Konnektoren zentral zu sperren;
- keine belastbare Antwort zum Ort von Speicherung und Inferenz;
- autonome externe Aktionen ohne Freigabe und Protokoll;
- Fachantworten ohne prüfbare Quellen bei rechtsrelevanten Use Cases;
- Vertragsbedingungen, die Berufsgeheimnis oder Mandantenpflichten nicht abbilden.

13. Ausblick: nächste 90 Tage

13.1 Mit hoher Wahrscheinlichkeit relevant

- praktische Vollzugshinweise zum geänderten AI Act und zum allgemeinen Anwendungsbeginn;
- Verkündung und operative Ausgestaltung des deutschen KI-Marktüberwachungs- und Innovationsgesetzes;
- Preisanpassungen nach Auslaufen der Claude-Sonnet-5-Einführungspreise am 31. August;
- weitere regionale Verfügbarkeit neuer Modelle, insbesondere Gemini 3.6 Flash und GPT-5.6 auf Cloud-Plattformen;
- tatsächliche Creditpreise und Verbrauchsmuster von ChatGPT for PowerPoint nach dem 6. August;
- Agenten- und MCP-Governance in Microsoft 365 sowie reale Sicherheits- und Kostenmuster;
- Roadmap des Zusammenschlusses Cohere/Aleph Alpha;
- Verfügbarkeit, Lizenz und Ausrichtung von Soofi-Modellen;
- konkrete DATEV-Roadmaps und Rollouts aus der AI-integrated-Strategie.

13.2 Radar-Signale

Signal	Grün	Gelb	Rot
Fachqualität	Quellenquote stabil, Fehler rückläufig	Rework steigt	kritische Falschaussage oder erfundene Quelle
Daten	geprüfte Region/Verträge	neue Funktion mit unklarem Routing	unzulässiger Drittland-/Trainingsfluss
Agenten	klarer Scope, Freigaben, Logs	neue Konnektoren oder Rechte	autonome Außenaktion/unkontrollierte Schleife

Signal	Grün	Gelb	Rot
Kosten	Vorgangskosten stabil	Credits/Token steigen >20 %	Budgetüberschreitung oder fehlende Zuordnung
Anbieter	planbare Release Notes	kurzfristige Modellablösung	Wegfall von Export, Region oder Schutzfunktion
Regulierung	dokumentierte Klassifikation	unklare Behördenauslegung	behördlicher Hinweis oder meldepflichtiger Vorfall

14. Grenzen des Berichts

- Der Markt ändert sich schneller als klassische Beschaffungszyklen; Verfügbarkeit und Preise können nach dem Stichtag abweichen.
- Nicht alle Anbieter veröffentlichen vollständige Subprozessor-, Residenz- oder Lizenzdetails ohne Vertragsanfrage.
- Produktnamen können mehrere Tarife mit unterschiedlichen Datenschutz- und Administrationsmerkmalen bezeichnen.
- Die Bewertung beruht auf öffentlichen Primärquellen, nicht auf Penetrationstests, Zertifizierungsaudits oder einer eigenen repräsentativen Kanzeibefragung.
- Anbieterbenchmarks wurden nicht unabhängig reproduziert.
- Dieser Bericht ist Markt- und Entscheidungseinordnung, keine Rechts-, Datenschutz- oder Berufsrechtsberatung für den Einzelfall.

15. Strukturiertes Quellenverzeichnis

Alle Quellen wurden zuletzt am 29. Juli 2026 abgerufen, sofern nicht anders angegeben.

15.1 Recht, Regulierung und Behörden

1. Europäische Union: Verordnung (EU) 2026/1744 zur Änderung des AI Act, veröffentlicht 24.07.2026.
2. Europäische Union: Verordnung (EU) 2024/1689 – Artificial Intelligence Act.
3. Deutscher Bundestag: KI-Marktüberwachungs- und Innovationsgesetz, Beratung 11.06.2026.
4. Bundesrat: 1067. Sitzung, KI-Marktüberwachungs- und Innovationsgesetz, 10.07.2026.
5. Bundesrat: Beratungsvorgang 375/26.
6. Bundesregierung: Umsetzung der KI-Verordnung.
7. Bundesnetzagentur: Künstliche Intelligenz – Aufgaben und Umsetzung.

15.2 Berufsstand und steuerfachlicher Markt

8. Deutscher Steuerberaterverband: Digitale Transformation in der Steuerberatung – 11 KI-Tools für Recherche und Assistenz 2026, Januar 2026.
9. Deutscher Steuerberaterverband: Muster-KI-Anwendungsrichtlinie, 23.04.2026.
10. DATEV: Pressemappe Jahrespressekonferenz 2026, 17.07.2026.
11. DATEV: Geschäftsbericht 2025, veröffentlicht 16.07.2026.
12. DATEV: Künstliche Intelligenz bei DATEV.
13. DATEV: LEXinform plus.
14. DATEV: Einspruchsgenerator.
15. DATEV: DATEV Copilot.
16. Haufe: CoPilot Tax – Shop und Pakete.
17. NWB: KIRA Kanzleipakete.
18. Stollfuß: GenIA-L Jahresabo.
19. Deubner: Deubner Tax KI.
20. Taxy.io: Answers.
21. Taxy.io: KI-Beta-Club.

15.3 OpenAI

22. OpenAI: Introducing GPT-5.6, 09.07.2026.
23. OpenAI: ChatGPT for your most ambitious work, 09.07.2026.
24. OpenAI Help Center: Connectors/Apps changes, Juli 2026.
25. OpenAI Help Center: ChatGPT Enterprise and Edu Release Notes.
26. OpenAI Help Center: ChatGPT Release Notes.
27. OpenAI Help Center: Data residency and inference residency.
28. OpenAI: Enterprise Privacy.

15.4 Anthropic

29. Anthropic: Claude Sonnet 5, 30.06.2026.
30. Anthropic: Claude Opus 5, 24.07.2026.
31. Anthropic Privacy Center: Server locations and EU hosting.

15.5 Google

32. Google: Gemini 3.6 Flash, 3.5 Flash-Lite and 3.5 Flash Cyber, 21.07.2026.
33. Google: Gemini Notebook, 16.07.2026.
34. Google Cloud: Gemini Enterprise locations.
35. Google Cloud: Generative AI data residency and training commitments.

15.6 Microsoft

- 36. Microsoft: Microsoft 365 Copilot Release Notes, Juli 2026.
- 37. Microsoft Partner Center: Announcements – June 2026.
- 38. Microsoft: Data, privacy, and security for Microsoft 365 Copilot.

15.7 AWS, SAP und europäische Plattformen

- 39. AWS: OpenAI GPT-5.6 in Amazon Bedrock, 13.07.2026.
- 40. AWS: GuardDuty AI Protection, 14.07.2026.
- 41. AWS: Bedrock product metadata in AWS Data Exports, 20.07.2026.
- 42. AWS: AgentCore unified observability, 23.07.2026.
- 43. AWS: Claude Opus 5 on AWS, 24.07.2026.
- 44. SAP: Business AI release highlights Q2 2026, 20.07.2026.
- 45. Mistral AI: Manage prompts and skills in Studio, 09.07.2026.
- 46. Mistral AI: OCR 4, 23.06.2026, außerhalb des Beobachtungsfensters.
- 47. Cohere: North Automations, 27.07.2026.
- 48. Cohere: Cohere and Aleph Alpha join forces, 24.04.2026, außerhalb des Beobachtungsfensters.
- 49. Schwarz Digits: Cohere und Aleph Alpha planen Zusammenschluss, 24.04.2026.
- 50. IONOS: Managed AI Model Hub.
- 51. IONOS: AI Model Hub – EU AI Act Governance.
- 52. STACKIT: Sovereign Cloud and AI.
- 53. OVHcloud: Q3 FY2026 financial and product update, 25.06.2026.

15.8 Weitere Modelle und Werkzeuge

- 54. Soofi Project: Soofi: An Open-Source 30B-A3B Bilingual Foundational Model, 10.07.2026.
 - 55. Soofi Project: Soofi-S-Base model card.
 - 56. xAI: Grok 4.5, 16.07.2026.
 - 57. xAI: Grok Excel Add-in, 20.07.2026.
 - 58. DeepL: Translation Flow, 06.07.2026.
 - 59. DeepL: Enterprise language AI – trust and quality, 26.06.2026.
 - 60. NVIDIA: Japan enterprises build specialized AI with Nemotron open models, 15.07.2026.
-

16. Redaktionsnotiz

Redaktionsschluss: 29. Juli 2026

Nächstes empfohlenes Update: spätestens 30. September 2026 oder früher bei wesentlichen Änderungen zu AI-Act-Vollzug, deutschem KI-MIG, DATEV-Rollouts, EU-Modellresidenz oder Preismodellen.

Transparente Annahme: Mangels organisationsspezifischer Angaben zielen die Empfehlungen auf typische deutsche Steuerkanzleien mit DATEV- und Microsoft-365-Nähe. Für Google-Workspace-, SAP- oder eigenentwicklungszentrierte Organisationen sind die Architekturpfade entsprechend zu verschieben.